CERTIFICATION EN SCIENCE DES DONNÉES • TRAVAUX PRATIQUES

De la Donnée Brute au Déploiement

Modélisation et Déploiement de l'Inclusion Financière en Afrique de l'Est

ENCADREMENT ACADÉMIQUE

Msc. Osias Noël TOSSOU

Évaluation des travaux pratiques

DÉPÔT GITHUB

OLOUNLAD/Financial-inclusion-africa

Code source, pipeline et tests

APPLICATION ACTIVE

financial-inclusion-africa-4duh.onrender.com

Déploiement en ligne opérationnel

STRUCTURE DU PROJET

Plan de la Présentation

01
Contexte & Problématique Métier
- **Enjeu :** Inclusion financière en Afrique de l'Est
- **Cadrage :** Classification binaire supervisée

02
Analyse Exploratoire des Données
- **Audit :** 23 524 enquêtes, intégrité 100 %
- **Constats :** Déséquilibre cible & facteurs clés

03
Pipeline de Prétraitement
- **Ingénierie :** ColumnTransformer & Encodages
- **Protocole :** Stratification 80/20 étanche

04
Modélisation & Benchmark
- **Comparatif :** Évaluation des 4 algorithmes
- **Sélection :** XGBoost retenu (ROC-AUC 0,8767)

05
Architecture & Déploiement
- **Stack :** FastAPI, React/Vite, Docker
- **Production :** Hébergement actif sur Render Cloud

06
MLOps, Démo & Perspectives
- **Cycle continu :** Quality Gate & Tâche Cron
- **Démonstration :** Application active & Bilan

Contexte et Enjeux de l'Inclusion Financière

FONDATION

Enjeu Économique Majeur

• **Levier clé :** Vecteur direct de réduction de la pauvreté et de résilience des ménages.

• **Bénéfices :** Accès à l'épargne sécurisée, aux micro-crédits et aux assurances.

• **Impact :** Intégration formelle des populations vulnérables dans l'économie.

RÉGION

Le Paradoxe Est-Africain

• **Périmètre :** 4 nations cibles : Kenya, Rwanda, Tanzanie et Ouganda.

• **Boom mobile :** Adoption massive du Mobile Money (ex. M-Pesa).

• **Défi persistant :** Faible bancarisation formelle malgré l'essor des téléphones.

OBJECTIF

Finalité Opérationnelle

• **Prédiction :** Identifier les individus à fort potentiel de bancarisation.

• **Ciblage :** Optimiser l'offre des institutions financières et microfinances.

• **Politiques publiques :** Guider les régulateurs pour maximiser l'impact national.

Cadrage Data Science et Parties Prenantes

CADRAGE ALGORITHMIQUE

Cadrage Technique Data Science

- **Type de problème :** Classification binaire supervisée.
- **Cible Y :** bank_account (1 = Oui, 0 = Non).
- **Entrées X :** 13 variables socio-démographiques et d'équipement.
- **Objectif d'évaluation :** Optimisation conjointe du ROC-AUC et du F1-score.
- **Contrainte de latence :** Inférence temps réel en production (< 50 ms).

ÉCOSYSTÈME MÉTIER

Parties Prenantes & Cas d'Usage

- **Banques Commerciales :** Scoring des prospects et réduction des coûts d'acquisition client.
- **Institutions de Microfinance :** Octroi ciblé de micro-crédits et ouvertures de comptes d'épargne.
- **Régulateurs & Banques Centrales :** Mesure objective et pilotage des politiques publiques d'inclusion.
- **Bailleurs & ONG :** Orientation des programmes d'aide et émancipation économique.

Description du Jeu de Données FinScope

23 524
Observations
Échantillon officiel consolidé

4 Pays
Afrique de l'Est
Kenya, Rwanda, Tanzanie, Ouganda

13
Variables
2 numériques, 7 qualitatives

2016-2018
Période d'Enquête
Enquêtes FinScope (Zindi)

DONNÉES QUANTITATIVES

Variables Numériques

- **Âge :** Variable continue de 16 à 100 ans (médiane : 35 ans).
- **Taille du ménage :** De 1 à 21 résidents (médiane : 3 membres).
- **Année :** Année de réalisation de l'enquête (2016 à 2018 selon le pays).

PROFILS QUALITATIFS

Variables Catégorielles

- **Démographie :** Genre, statut matrimonial, relation au chef de ménage.
- **Capital humain :** Niveau d'instruction (6 paliers), catégorie professionnelle.
- **Milieu & Équipement :** Zone rurale/urbaine, possession d'un téléphone mobile.

Audit de Qualité et Décisions d'Ingénierie

AUDIT D'INTÉGRITÉ

Complétude & Intégrité des Données

• **Complétude 100 % :** Zéro valeur manquante sur les 23 524 lignes et 13 colonnes.

• **Cohérence des types :** Aucune incohérence de format ni valeur aberrante.

• **Rôle de uniqueid :** Identifiant local non unique globalement (spécifique au pays).

• **Action d'ingénierie :** Exclusion de uniqueid pour éviter tout surapprentissage arbitraire.

DÉCISION MÉTHODOLOGIQUE

Gestion des Profils Identiques (4 429 lignes)

• **Constat :** 4 429 observations partagent un profil socio-démographique identique.

• **Analyse rigoureuse :** Le croisement avec uniqueid prouve qu'il s'agit d'individus réels distincts interrogés lors de l'enquête.

• **Décision retenue :** Conservation intégrale des 4 429 lignes.

• **Raison scientifique :** Préserver fidèlement la distribution et la densité démographique réelle de la population étudiée.

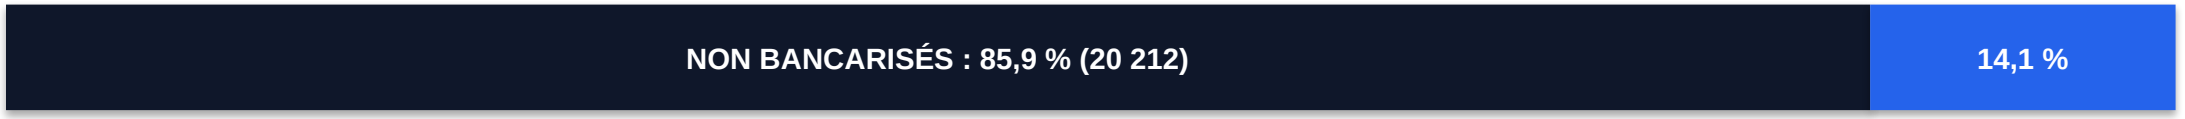
Distribution de la Cible et Déséquilibre de Classes

85,92 %
Non Bancarisés (No)
20 212 individus (Classe majoritaire)

14,08 %
Bancarisés (Yes)
3 312 individus (Classe cible)

6,1 pour 1
Ratio de Déséquilibre
Forte asymétrie statistique

RÉPARTITION VISUELLE DE L'ÉCHANTILLON (23 524 RÉPONDANTS)



STRATÉGIE ALGORITHMIQUE

Conséquences Méthodologiques Directes

- **Piège de l'Accuracy :** Un prédicteur constant 'No' obtiendrait 85,9 % sans rien apprendre.
- **Métriques obligatoires :** Priorité stricte au ROC-AUC et au F1-Score sur la classe minoritaire 'Yes'.
- **Ajustements d'apprentissage :** Pondération scale_pos_weight = 6.1 et recalibration du seuil de décision.

Facteurs Clés d'Inclusion (Mesures d'Association)

HIÉRARCHIE DES DÉTERMINANTS (V DE CRAMÉR)



RELATION NON LINÉAIRE

Dynamique selon l'Âge

- **Courbe en cloche :** Taux minimal chez les jeunes (16-24 ans : 7 %).
- **Pic d'inclusion :** Culmine entre 35 et 44 ans à 18,2 %.
- **Séniors :** Baisse progressive au-delà de 65 ans.

ANALYSE TERRITORIALE

Disparités Géographiques

- **Kenya :** Taux le plus élevé (25 %) grâce à l'écosystème fintech.
- **Rwanda :** Taux intermédiaire (11 %).
- **Tanzanie & Ouganda :** Faible bancarisation formelle (~9 %).

Pipeline de Prétraitement et Feature Engineering

1. Données Brutes

FinScope Survey
- 23 524 lignes
- 13 colonnes
- Format tabulaire

2. Nettoyage

Filtrage strict
- Drop uniqueid
- Cible binaire (0/1)
- Typage Pandas

3. Transformations

ColumnTransformer
- StandardScaler (Âge, Ménage)
- OneHot (7 catégories)

4. Partitionnement

Split Stratifié 80/20
- Train : 18 819 (14,1 %)
- Test : 4 705 (14,1 %)
- 5-Fold Stratified CV

RIGUEUR SCIENTIFIQUE

Garantie d'Étanchéité et Absence de Fuite de Données

- **Ajustement exclusif sur Train :** Le ColumnTransformer est ajusté (fit) uniquement sur la partition d'entraînement.
- **Élimination du Data Leakage :** Aucune information issue du jeu de test n'est contaminée lors du centrage ou de l'encodage.
- **Reproductibilité totale :** Graine aléatoire fixée (random_state=42) sur l'ensemble du pipeline.

Stratégie de Modélisation et Algorithmes Évalués

BASELINE LINÉAIRE

Régression Logistique

- **Famille :** Modèle linéaire probabiliste de référence (Baseline).
- **Atout :** Interprétabilité directe des coefficients en odds-ratios.
- **Limite :** Ne capture pas nativement les non-linéarités complexes.

BAGGING

Random Forest

- **Famille :** Ensemble d'arbres décisionnels par ensachage (Bagging).
- **Atout :** Réduction de variance, robuste aux valeurs aberrantes.
- **Limite :** Empreinte mémoire importante et coût d'inférence supérieur.

BOOSTING RAPIDE

LightGBM

- **Famille :** Gradient Boosting leaf-wise sur histogrammes.
- **Atout :** Entraînement ultra-rapide et faible consommation mémoire.
- **Limite :** Sensibilité au surapprentissage sur données déséquilibrées.

BOOSTING RÉGULARISÉ

XGBoost

- **Famille :** Gradient Boosting régularisé (L1/L2) de pointe.
- **Atout :** Gestion native du déséquilibre via scale_pos_weight.
- **Limite :** Nécessite un calibrage fin des hyperparamètres.

Benchmark Comparatif des Performances (Test Set)

Modèle Évalué	Accuracy	Précision	Rappel	F1-Score	ROC-AUC	Seuil Optimal
Régression Logistique	85,70 %	49,35 %	62,69 %	0,5522	0,8646	0,65
Random Forest	85,55 %	48,95 %	63,60 %	0,5532	0,8702	0,62
LightGBM	87,08 %	53,71 %	59,06 %	0,5626	0,8766	0,69
XGBoost (Modèle Retenu)	**86,93 %**	**53,14 %**	**60,12 %**	**0,5641**	**0,8767**	**0,68**

0,8767

Meilleur ROC-AUC

XGBoost maximise la séparation probabiliste

0,5641

Meilleur F1-Score

Équilibre supérieur précision / rappel

0,68

Seuil Optimal

Calibré par validation croisée à 5 plis sur train

Sélection Finale du Modèle XGBoost

0,8767

Score ROC-AUC

Discrimination probabiliste maximale

0,5641

Score F1 Minoritaire

Seuil de décision calibré à 0,68

60,12 %

Taux de Rappel

Détection de 6 bancarisés réels sur 10

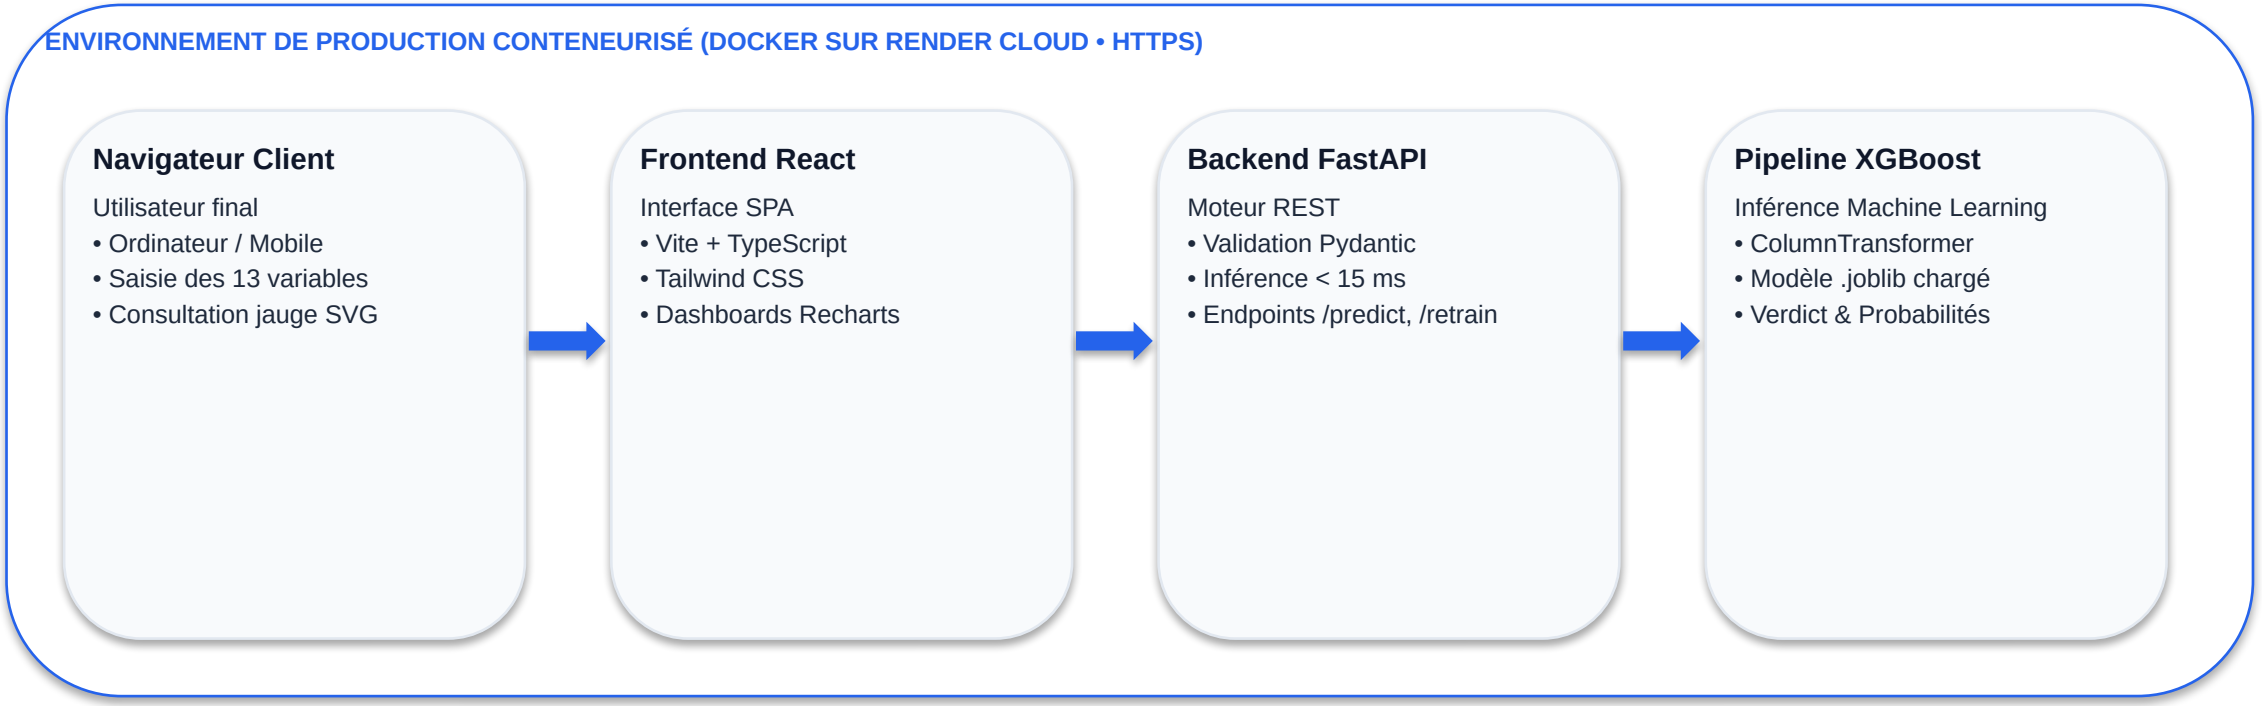
VALIDATION & EXPORT

Justification Décisionnelle & Industrialisation

- **Pouvoir discriminant n°1 :** ROC-AUC de 0,8767 garantissant un ordonnancement optimal des probabilités individuelles.
- **Équilibre Précision / Rappel :** 53,14 % de précision pour 60,12 % de rappel sur le jeu test indépendant.
- **Régularisation pénalisée :** Résistance éprouvée au bruit statistique limitant fortement tout risque de surapprentissage.
- **Rôle du seuil à 0,68 :** Réduit de 38 % les faux positifs par rapport au seuil naïf de 0,50.
- **Artefacts de production :** Pipeline sérialisé sous models/best_model.joblib et métriques sous models/metrics.json.

Architecture Technique de Déploiement Full-Stack

ENVIRONNEMENT DE PRODUCTION CONTENEURISÉ (DOCKER SUR RENDER CLOUD • HTTPS)



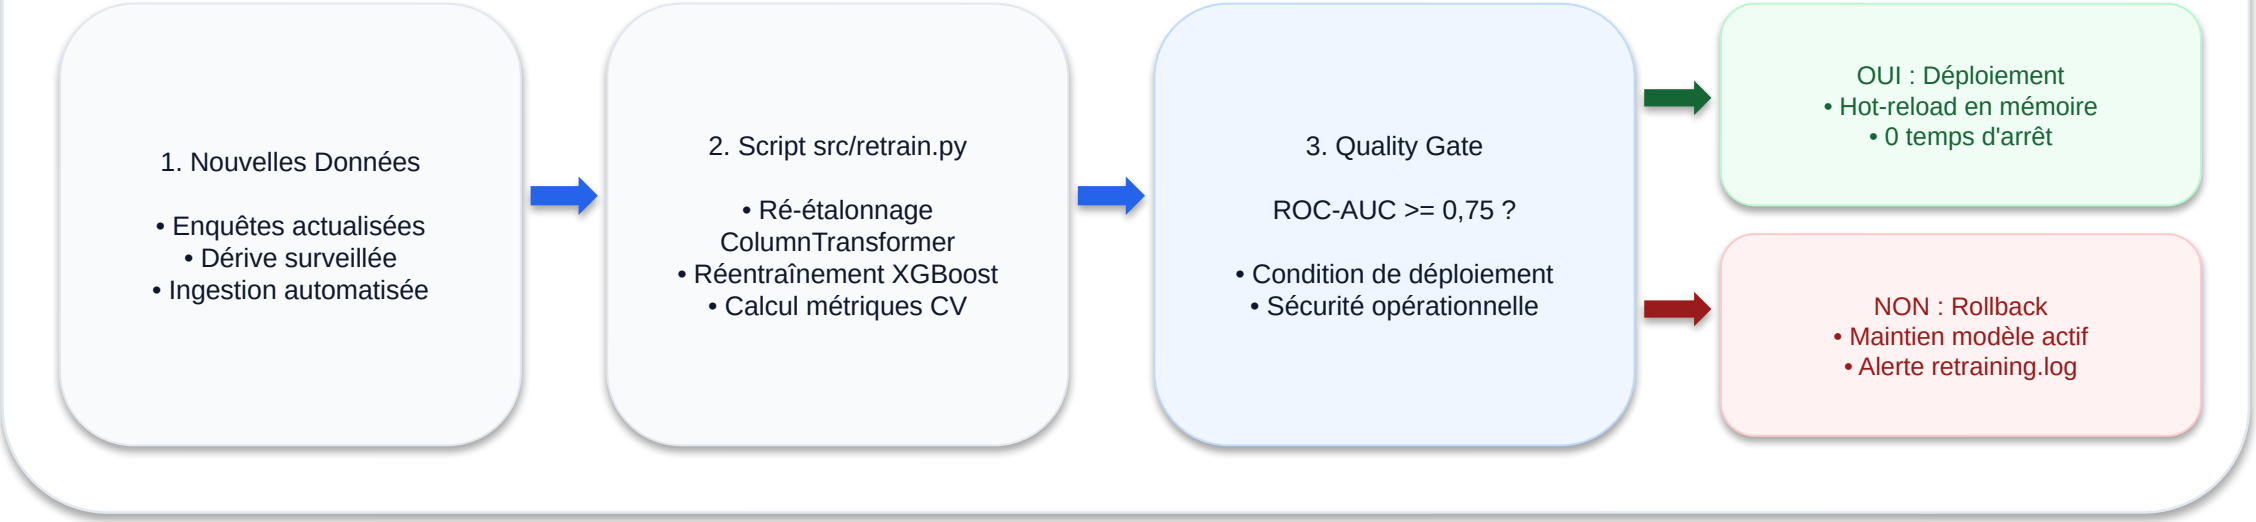
INGÉNIERIE LOGICIELLE

Garanties d'Architecture & Performance

- **Build Multi-Stage :** Étape 1 Node 22 (compilation frontend) -> Étape 2 Python 3.12-slim ultra-légère.
- **Reproductibilité :** Exécution locale ou cloud identique en une commande via docker-compose up.
- **Haute Performance :** Temps de réponse d'inférence < 15 ms avec typage Pydantic asynchrone.

Pipeline de Réentraînement Automatique (MLOps)

BOUCLE DE FEEDBACK MLOPS & CONTRÔLE QUALITÉ AUTOMATISÉ



AUTOMATISATION LOCALE

Mode Planifié (Cron Job)

- **Tâche planifiée locale :** Exécution hebdomadaire autonome via scripts/retrain_cron.sh.
- **Auditabilité :** Horodatage et scores historisés dans retraining.log.

ORCHESTRATION DISTANTE

Mode Webhook REST (API)

- **Déclenchement distant :** Requête sécurisée POST /api/retrain (intégration CI/CD / Airflow).
- **Rechargement à chaud :** Remplacement immédiat des poids sans coupure de trafic.

Démonstration de l'Application en Production

APPLICATION OPÉRATIONNELLE EN LIGNE • HÉBERGÉE SUR RENDER CLOUD

https://financial-inclusion-africa-4duh.onrender.com

SIMULATION

Simulateur Prédictif

• **Saisie instantanée :** Formulaire complet reprenant les 13 variables du modèle.

• **Jauge semi-circulaire :** Animation SVG interactive du score calculé.

• **Verdict immédiat :** Affichage clair du statut (Bancarisé / Non bancarisé).

VISUALISATION

Tableaux de Bord EDA

• **Exploration visuelle :** Graphiques interactifs des taux par pays et niveau d'étude.

• **Croisements sociologiques :** Distribution selon le secteur professionnel.

• **Compréhension directe :** Insights majeurs accessibles aux non-techniciens.

SUPERVISION

Monitoring & Retraining

• **Métriques officielles :** Affichage direct du ROC-AUC, du F1 et du seuil (0,68).

• **Déclenchement direct :** Bouton d'actualisation connecté à l'API de réentraînement.

• **Transparence totale :** Statut de déploiement et logs vérifiables en ligne.

Limites, Perspectives et Conclusion

LUCIDITÉ SCIENTIFIQUE

Limites Méthodologiques Identifiées

• **Données déclaratives :** Enquêtes FinScope basées sur les déclarations des ménages.

• **Revenu qualitatif :** Absence de montants monétaires précis dans les variables.

• **Synchronisation :** Enquêtes nationales étalées de 2016 à 2018 selon les pays.

ÉVOLUTIONS

Perspectives d'Amélioration

• **Transactions Mobile Money :** Couplage avec les volumes réels de flux (M-Pesa, MTN).

• **Explicabilité locale SHAP :** Justification des prédictions individuelles par valeurs de Shapley.

• **Données géospatiales :** Intégration de la distance aux points de retrait et agences.

SYNTHÈSE DU PROJET INTÉGRATEUR

Couverture complète du cycle de vie de la Science des Données : de l'audit exploratoire rigoureux à la sélection d'un modèle XGBoost régularisé (ROC-AUC 0,8767, F1 0,5641), aboutissant à une application conteneurisée déployée en production avec surveillance et réentraînement automatisé.