CERTIFICATION EN SCIENCE DES DONNÉES • TRAVAUX PRATIQUES

De la Donnée Brute au Déploiement

Modélisation et Déploiement de l'Inclusion Financière en Afrique de l'Est

ENCADREMENT ACADÉMIQUE

Msc. Osias Noël TOSSOU

Évaluation des travaux pratiques

DÉPÔT GITHUB

OLOUNLAD/Financial-inclusion-africa

Code source, pipeline et tests

DÉPLOIEMENT CLOUD

financial-inclusion-africa-4duh.onrender.com

Application web opérationnelle

STRUCTURE DU PROJET

Plan Structuré de la Soutenance

01
Contexte & Problématique Métier

• **Enjeu :** Inclusion financière en Afrique de l'Est

• **Cadrage :** Classification binaire et parties prenantes

02
Analyse Exploratoire des Données (EDA)

• **Audit :** 23 524 observations, intégrité et doublons

• **Constats :** Déséquilibre de classe et facteurs clés

03
Prétraitement & Feature Engineering

• **Pipeline :** ColumnTransformer scikit-learn rigoureux

• **Découpage :** Stratification 80/20 sans data leakage

04
Modélisation & Benchmark Comparatif

• **Algorithmes :** Régression Logistique, RF, LightGBM, XGBoost

• **Sélection :** XGBoost retenu (ROC-AUC 0,8767, seuil 0,68)

05
Architecture & Déploiement Full-Stack

• **Backend / Frontend :** FastAPI haute performance & React Vite

• **Conteneurisation :** Multi-stage Docker sur Render Cloud

06
MLOps, Démonstration & Bilan

• **Automatisation :** Quality gate ROC-AUC >= 0,75 & Cron

• **Synthèse :** Démonstration active, limites et perspectives

Contexte et Enjeux de l'Inclusion Financière

FONDATION

Levier de Développement

Rôle central : Vecteur essentiel de réduction de la pauvreté et de résilience face aux chocs économiques.

Bénéfices directs : Permet l'accès à l'épargne sécurisée, au micro-crédit d'investissement et à l'assurance.

Enjeu macro : Intégration formelle de populations historiquement marginalisées dans l'économie structurée.

GÉOGRAPHIE

Contexte Régional Est-Africain

Périmètre géographique : Étude concentrée sur 4 nations clés : Kenya, Rwanda, Tanzanie et Ouganda.

Boom technologique : Pénétration fulgurante du Mobile Money (ex. M-Pesa au Kenya).

Paradoxe persistant : Malgré les portefeuilles mobiles, une très large majorité n'a toujours aucun compte bancaire formel.

OBJECTIF

Finalité Opérationnelle

Détection prédictive : Identifier avec précision les profils individuels susceptibles d'adopter des services bancaires.

Orientation des offres : Aider les banques et institutions de microfinance à concevoir des produits adaptés.

Politiques publiques : Guider les régulateurs pour maximiser l'impact des campagnes nationales d'inclusion.

Cadrage Data Science et Parties Prenantes

CADRAGE ALGORITHMIQUE

Formulation Mathématique & Technique

Type de problème : Classification binaire supervisée.

Variable cible (Y) : bank_account (1 = Yes, 0 = No).

Variables d'entrée (X) : 13 attributs socio-démographiques, économiques et d'équipement technologique.

Nature des données : Données tabulaires d'enquêtes individuelles (FinScope).

Critère d'évaluation : Optimisation du ROC-AUC et du F1-Score sur la classe minoritaire pour contrer le déséquilibre.

Contrainte de production : Temps de latence d'inférence < 50 ms pour le déploiement API.

ÉCOSYSTÈME & VALEUR

Acteurs Concernés & Cas d'Usage Métier

Banques Commerciales : Scoring prédictif des prospects, optimisation des coûts d'acquisition et ciblage des campagnes.

Institutions de Microfinance : Attribution sécurisée de micro-crédits et ouverture de comptes d'épargne ruraux.

Régulateurs & Banques Centrales : Suivi précis des indicateurs nationaux d'inclusion et pilotage des réglementations.

Bailleurs & ONG de Développement : Évaluation de l'efficacité des programmes d'aide et autonomisation financière des femmes.

Description du Jeu de Données FinScope

23 524
Observations
Échantillon consolidé

4 Pays
Afrique de l'Est
Kenya, Rwanda, TZ, UG

13
Variables
2 numériques, 7 qualitatives

2016-2018
Période d'Enquête
Données Zindi Africa

DISTRIBUTIONS QUANTITATIVES

Variables Numériques & Temporelles

Âge de l'individu : Variable continue s'étendant de 16 à 100 ans (médiane : 35 ans).

Taille du ménage : Nombre de personnes résidant sous le même toit : 1 à 21 (médiane : 3 personnes).

Année d'enquête : Année de réalisation de l'enquête FinScope (2016, 2017 ou 2018 selon le pays).

PROFILS SOCIO-ÉCONOMIQUES

Variables Catégorielles Déterminantes

Socio-démographie : Genre, statut matrimonial, relation au chef de ménage.

Capital humain & Emploi : Niveau d'instruction (6 catégories), secteur d'activité / profession.

Environnement & Équipement : Milieu de résidence (Rural / Urban) et possession d'un téléphone mobile personnel.

Audit de la Qualité et Intégrité des Données

AUDIT D'INTÉGRITÉ

Complétude & Cohérence Globale

Exhaustivité parfaite : Zéro valeur manquante sur l'ensemble des 23 524 lignes et 13 colonnes (100 % de complétude).

Cohérence des types : Aucune incohérence de format détectée ; les valeurs numériques et catégorielles sont rigoureusement valides.

Rôle de l'identifiant (uniqueid) : L'identifiant n'est pas unique à l'échelle globale, mais uniquement par pays.

Traitement d'ingénierie : La colonne uniqueid a été retirée du pipeline d'apprentissage pour éliminer tout risque d'apprentissage par cœur arbitraire.

DÉCISION MÉTHODOLOGIQUE CLÉ

Traitement des Profils Identiques

Constat initial : 4 429 lignes partagent des combinaisons de variables socio-démographiques exactement identiques.

Vérification approfondie : Le croisement avec uniqueid prouve qu'il s'agit d'individus différents partageant des caractéristiques similaires (ex. 2 agriculteurs ruraux de 40 ans sans instruction).

Décision méthodologique : Conservation intégrale des 4 429 observations.

Justification : Supprimer ces lignes aurait faussé la distribution réelle de la population en sous-représentant les profils démographiques les plus fréquents.

Distribution de la Cible et Déséquilibre de Classes

85,92 %
Non Bancarisés (No)
20 212 répondants dans l'échantillon

14,08 %
Bancarisés (Yes)
3 312 répondants dans l'échantillon

6,1 : 1
Ratio de Déséquilibre
6 non bancarisés pour 1 bancarisé

STRATÉGIE DE MODÉLISATION

Implications Méthodologiques Majeures

Piège de l'Accuracy brute : Un prédicteur constant qui répondrait systématiquement 'No' obtiendrait une exactitude artificielle de 85,92 % tout en étant parfaitement inutile sur le plan métier.

Sélection de métriques robustes : Priorité stricte accordée au ROC-AUC (mesure du pouvoir séparateur global des probabilités) et au F1-Score sur la classe minoritaire 'Yes'.

Stratégie algorithmique : Introduction de pénalités de déséquilibre (scale_pos_weight = 6.1) pour forcer les modèles à accorder une importance équivalente aux profils bancarisés.

Calibration du seuil : Optimisation du seuil de décision au-delà de 0,50 pour équilibrer précisément précision et rappel.

Principaux Enseignements Statistiques

DÉTERMINANT #1

Niveau d'Instruction

Cramér's V = 0,392 : Déterminant statistique numéro 1 de l'inclusion financière.

Gradient spectaculaire : Le taux de bancarisation passe de 4 % chez les personnes sans éducation formelle à plus de 57 % au niveau universitaire.

DÉTERMINANT #2

Type d'Activité & Emploi

Cramér's V = 0,361 : Déterminant majeur lié à la régularité des flux de revenus.

Contraste formel / informel : 77 % de bancarisation chez les fonctionnaires et 54 % dans le privé formel, contre < 8 % dans l'agriculture vivrière.

INFRASTRUCTURE

Téléphone Mobile

Cramér's V = 0,208 : Condition sine qua non d'accès aux services financiers modernes.

Écart marqué : 18 % de bancarisation chez les détenteurs de téléphone contre à peine 2 % chez ceux qui n'en possèdent pas.

DÉMOGRAPHIE

Âge & Territoire

Dynamique d'âge : Relation non linéaire en cloche : l'accès bancaire culmine sur la tranche 35-44 ans (18,2 %) avant de redescendre.

Disparités géographiques : Le Kenya domine largement (25 % de bancarisation), suivi du Rwanda (11 %), de la Tanzanie (9 %) et de l'Ouganda (9 %).

Pipeline de Prétraitement et Feature Engineering

ÉTAPE 1

1. Nettoyage & Filtrage

Exclusion uniqueid : Élimination des identifiants non généralisables.

Encodage de la cible : Transformation binaire propre de bank_account ('Yes' -> 1, 'No' -> 0).

Validation des formats : Contrôle des types stricts sous Pandas pour éviter toute incohérence.

ÉTAPE 2

2. ColumnTransformer Scikit-Learn

StandardScaler : Centrage et réduction des variables numériques (âge, taille du ménage, année).

OneHotEncoder : Encodage disjonctif complet des variables qualitatives avec handle_unknown='ignore'.

Sécurité leakage : Ajustement exclusif sur les données d'entraînement (fit sur train uniquement).

ÉTAPE 3

3. Partitionnement Stratifié

Répartition 80 / 20 : 18 819 individus pour l'entraînement, 4 705 pour le test indépendant.

Stratification stricte : Préservation exacte du ratio de 14,08 % de bancarisés dans les deux partitions.

Validation croisée : 5-Fold Stratified K-Fold pour la sélection et le réglage des seuils.

Stratégie de Modélisation et Algorithmes Évalués

BASELINE

Régression Logistique

Famille : Modèle linéaire probabiliste.

Rôle : Sert de référence de base (Baseline).

Points forts : Calcul instantané, interprétabilité directe des coefficients en odds-ratios.

Limites : Incapacité à capturer nativement les interactions non linéaires complexes.

BAGGING

Forêt Aléatoire (Random Forest)

Famille : Ensemble par ensachage d'arbres (Bagging).

Rôle : Capture des relations non linéaires et réduction de variance.

Points forts : Robustesse face au bruit statistique, absence d'hypothèse de linéarité.

Limites : Taille mémoire importante et temps d'inférence modéré.

BOOSTING RAPIDE

LightGBM

Famille : Gradient Boosting leaf-wise sur histogrammes.

Rôle : Compétiteur moderne haute performance.

Points forts : Vitesse d'entraînement remarquable, faible empreinte mémoire.

Limites : Sensibilité au surapprentissage sur les petits sous-échantillons.

BOOSTING RÉGULARISÉ

XGBoost

Famille : Gradient Boosting avec régularisation L1 et L2.

Rôle : Algorithme de pointe pour données tabulaires.

Points forts : Excellente gestion du déséquilibre (scale_pos_weight) et généralisation optimale.

Limites : Réglage fin des hyperparamètres nécessaire.

Benchmark Comparatif des Performances (Test Set)

Algorithme	Accuracy	Précision	Rappel	F1-Score	ROC-AUC	Seuil Optimal
Régression Logistique	85,70 %	49,35 %	62,69 %	0,5522	0,8646	0,65
Random Forest	85,55 %	48,95 %	63,60 %	0,5532	0,8702	0,62
LightGBM	87,08 %	53,71 %	59,06 %	0,5626	0,8766	0,69
XGBoost (Modèle Retenu)	**86,93 %**	**53,14 %**	**60,12 %**	**0,5641**	**0,8767**	**0,68**

0,8767

Meilleur ROC-AUC

XGBoost domine le pouvoir discriminant global

0,5641

Meilleur F1-Score

Équilibre maximal entre précision et rappel

0,68

Seuil Optimal

Optimisé par cross-validation à 5 plis sur train

Sélection Finale du Modèle XGBoost

0,8767

Score ROC-AUC

Séparation probabiliste optimale

0,5641

Score F1 Minoritaire

Seuil de décision calibré à 0,68

60,12 %

Taux de Rappel

Détection de 6 bancarisés réels sur 10

CHOIX FINAL & ARTEFACTS

Justification Décisionnelle & Exportation

Excellence du compromis métrique : XGBoost délivre le meilleur score F1 (0,5641) tout en conservant une précision de 53,14 % et un rappel de 60,12 % sur l'échantillon test indépendant.

Robustesse prouvée par régularisation : L'application des pénalités L2 et le sous-échantillonnage préviennent tout surapprentissage sur les profils d'enquêtes marginaux.

Rôle clé du seuil optimisé (0,68) : Le seuil standard à 0,50 générait un excès de faux positifs. Le seuil à 0,68 calibré par validation croisée garantit que seules les opportunités qualifiées sont ciblées.

Sérialisation pour la production : Pipeline complet sérialisé dans models/best_model.joblib et métriques archivées dans models/metrics.json.

Architecture Technique de Déploiement Full-Stack

BACKEND INFERENCE

Moteur REST FastAPI

Framework moderne : API Python asynchrone haute performance.

Validation Pydantic : Typage strict et contrôle d'intégrité des entrées.

Rapidité d'inférence : Temps de réponse moyen < 15 ms par requête.

Points de terminaison : /api/predict, /api/metrics, /api/stats, /api/retrain.

FRONTEND INTERACTIF

Interface Web React + Vite

Technologies : React 18, Vite, TypeScript et Tailwind CSS.

Jauge dynamique SVG : Animation semi-circulaire intuitive du score de bancarisation.

Dashboards analytiques : Graphiques interactifs Recharts reproduisant l'EDA.

Expérience fluide : Simulation instantanée et responsive multi-écrans.

DEVOPS & CLOUD

Conteneurisation Cloud

Multi-Stage Docker : Étape 1 : compilation TypeScript (Node 22) -> Étape 2 : image de production Python 3.12-slim.

Optimisation image : Empreinte minimale intégrant Uvicorn et libgomp1.

Orchestration locale : docker-compose up pour exécution reproductible.

Hébergement Render : Déploiement cloud avec HTTPS actif et redémarrage automatique.

Pipeline de Réentraînement Automatique (MLOps)

AUTOMATISATION

Pipeline Dédié (src/retrain.py)

Objectif central : Prévenir la dérive des données (Data Drift) et la dérive de concept (Concept Drift) face aux nouvelles enquêtes.

Traitement bout-en-bout : Rechargement des données, ré-étalonnage du ColumnTransformer et réentraînement du modèle.

Traçabilité continue : Journalisation systématique dans retraining.log avec date, version et scores obtenus.

CONTRÔLE QUALITÉ

Quality Gate de Sécurité

Garde-fou automatisé : Déploiement conditionné à un score de performance strict : ROC-AUC >= 0,75.

Protection de la production : Si le nouveau modèle sous-performe, l'ancien modèle est immédiatement maintenu sans interruption.

Auditabilité totale : Conservation des métriques comparées avant/après chaque cycle.

OPÉRABILITÉ

Modes d'Exécution Flexibles

Tâche planifiée locale : Script Cron (scripts/retrain_cron.sh) pour exécution périodique autonome.

Webhook API sécurisé : Endpoint POST /api/retrain pour intégration avec orchestrateurs externes (ex. Airflow).

Rechargement à chaud : Mise à jour en mémoire vive sans nécessiter de redémarrage du serveur Uvicorn.

Démonstration de l'Application en Production

APPLICATION EN LIGNE • STATUT OPÉRATIONNEL SUR RENDER CLOUD

https://financial-inclusion-africa-4duh.onrender.com

SIMULATION

Simulateur Prédictif

Saisie ergonomique : Formulaire complet reprenant l'ensemble des 13 variables individuelles.

Verdict en temps réel : Animation semi-circulaire de la jauge et décision binaire instantanée.

Interprétation : Présentation claire de la probabilité de bancarisation estimée.

VISUALISATION

Tableau de Bord EDA

Analyses graphiques : Visualisations interactives des taux d'inclusion par nation.

Croisements sociologiques : Distribution selon le niveau d'instruction et la catégorie professionnelle.

Accès immédiat : Consultation directe des insights sans prérequis technique.

SUPERVISION

Monitoring & Retraining

Métriques officielles : Affichage en direct du ROC-AUC, du F1-Score et du seuil retenu (0,68).

Déclenchement réentraînement : Bouton d'actualisation connecté à l'API de réentraînement.

Transparence : Matrice de confusion et statut de déploiement en direct.

Limites, Perspectives et Conclusion

LUCIDITÉ SCIENTIFIQUE

Limites Méthodologiques Identifiées

Données purement déclaratives : Les enquêtes FinScope reposent sur les déclarations des ménages (biais de mémorisation ou d'approbation sociale).

Revenu qualitatif : La variable de source de revenu ne quantifie pas le montant monétaire précis des flux financiers.

Décalage temporel entre pays : Les enquêtes nationales ont été collectées entre 2016 et 2018 selon les nations.

ÉVOLUTIONS

Perspectives d'Amélioration Future

Flux transactionnels Mobile Money : Coupler les enquêtes avec les métriques réelles d'usage (ex. volumes M-Pesa, fréquence des transferts).

Explicabilité locale (SHAP) : Intégrer les valeurs de Shapley pour justifier chaque score prédictif individuel auprès du client.

Données géospatiales : Intégrer la distance physique aux agences bancaires et aux points de retrait d'argent.

SYNTHÈSE DU PROJET INTÉGRATEUR

Couverture complète du cycle de vie de la Science des Données : de l'audit exploratoire rigoureux à l'entraînement comparatif et la sélection d'un modèle XGBoost régularisé (ROC-AUC 0,8767, F1 0,5641), aboutissant à une application conteneurisée déployée en production avec surveillance et réentraînement automatisé.