TRAVAUX PRATIQUES • CERTIFICATION EN SCIENCE DES DONNÉES

Financial Inclusion in Africa

Dataset Officiel FinScope (Zindi) • 23 524 Individus • Kenya, Rwanda, Tanzanie, Ouganda

De la Donnée d'Enquête Brute au Déploiement MLOps en Production

ENCADREMENT ACADÉMIQUE

Msc. Osias Noël TOSSOU

Évaluation officielle des travaux pratiques

SOURCE & DÉPÔT CODE

Zindi Africa • GitHub

github.com/OLOUNLAD/Financial-inclusion-africa

APPLICATION DÉPLOYÉE

En Production sur Render

financial-inclusion-africa-4duh.onrender.com

STRUCTURE DU PROJET

Plan de la Présentation

01
Contexte & Problématique Métier
• **Enjeu :** Inclusion financière en Afrique de l'Est
• **Cadrage :** Classification binaire supervisée

02
Analyse Exploratoire des Données
• **Audit :** 23 524 enquêtes, intégrité 100 %
• **Constats :** Déséquilibre cible & facteurs clés

03
Pipeline de Prétraitement
• **Ingénierie :** ColumnTransformer & Encodages
• **Protocole :** Stratification 80/20 étanche

04
Modélisation & Benchmark
• **Comparatif :** Évaluation des 4 algorithmes
• **Sélection :** XGBoost retenu (ROC-AUC 0,8767)

05
Architecture & Déploiement
• **Stack :** FastAPI, React/Vite, Docker
• **Production :** Hébergement actif sur Render Cloud

06
MLOps, Démo & Perspectives
• **Cycle continu :** Quality Gate & Tâche Cron
• **Démonstration :** Application active & Bilan

Contexte et Enjeux de l'Inclusion Financière

FONDATION

Enjeu Économique Majeur

• **Levier direct :** Moteur central de réduction de la pauvreté et de résilience des ménages.

• **Bénéfices :** Accès à l'épargne sécurisée, au crédit productif et aux assurances.

• **Intégration :** Formalisation de l'activité économique des populations vulnérables.

Point Clé : Réduction de la pauvreté

RÉGION

Le Paradoxe Est-Africain

• **Périmètre :** 4 économies cibles : Kenya, Rwanda, Tanzanie et Ouganda.

• **Mobile Money :** Essor spectaculaire des paiements mobiles (ex. M-Pesa).

• **Retard bancaire :** Persistance d'un faible taux de bancarisation formelle.

Point Clé : Boom mobile vs Banques

OBJECTIF

Finalité Opérationnelle

• **Scoring prédictif :** Identifier avec précision les profils éligibles à la bancarisation.

• **Offres adaptées :** Guider les banques et microfinances dans leur ciblage.

• **Politiques d'inclusion :** Éclairer les banques centrales et les gouvernements.

Point Clé : Ciblage et inclusion

Cadrage Data Science et Parties Prenantes

CADRAGE ALGORITHMIQUE

Cadrage Technique Data Science

- **Formulation :** Classification binaire supervisée.
- **Cible Y :** bank_account (1 = Oui, 0 = Non).
- **Entrées X :** 13 variables démographiques, économiques et d'équipement.
- **Métriques de pilotage :** Optimisation conjointe du ROC-AUC et du F1-Score minoritaire.
- **Contrainte opérationnelle :** Temps d'inférence en production < 15 millisecondes.

Point Clé : Prédire la bancarisation en < 15 ms

ÉCOSYSTÈME MÉTIER

Parties Prenantes & Cas d'Usage

- **Banques Commerciales :** Scoring des prospects et réduction des coûts d'acquisition.
- **Microfinances :** Octroi ciblé de micro-crédits et ouverture de comptes d'épargne.
- **Régulateurs & Banques Centrales :** Mesure objective et pilotage des politiques publiques d'inclusion.
- **Bailleurs & ONG :** Orientation des subventions et autonomisation économique des femmes.

Point Clé : Valeur bancaire et impact public

Description du Jeu de Données FinScope

23 524
Observations
Échantillon officiel Zindi Africa

4 Pays
Afrique de l'Est
Kenya, Rwanda, Tanzanie, Ouganda

13
Variables
2 numériques, 7 qualitatives

2016-2018
Période d'Enquête
Enquêtes nationales FinScope

DONNÉES QUANTITATIVES

Variables Numériques (2)

- **Âge :** Variable continue de 16 à 100 ans (médiane : 35 ans).
- **Taille du ménage :** De 1 à 21 résidents (médiane : 3 membres).
- **Année d'enquête :** Réalisation de 2016 à 2018 selon le pays.

PROFILS QUALITATIFS

Variables Catégorielles (7)

- **Démographie :** Genre, statut matrimonial, relation au chef de ménage.
- **Capital humain :** Niveau d'instruction (6 paliers), catégorie professionnelle.
- **Équipement & Territoire :** Zone rurale/urbaine, possession d'un téléphone mobile.

Audit de Qualité et Décisions d'Ingénierie

AUDIT D'INTÉGRITÉ

Complétude & Intégrité des Données

• **Complétude 100 % :** Zéro valeur manquante sur les 23 524 lignes et 13 variables.

• **Cohérence des données :** Aucune incohérence de format ni valeur aberrante.

• **Rôle de uniqueid :** Identifiant local non unique globalement (spécifique au pays).

• **Action d'ingénierie :** Exclusion de uniqueid pour éliminer tout surapprentissage arbitraire.

Point Clé : **Données exhaustives à 100 %**

DÉCISION MÉTHODOLOGIQUE

Gestion des Profils Identiques (4 429 lignes)

• **Constat :** 4 429 observations partagent un profil socio-démographique identique.

• **Vérification :** Le croisement avec uniqueid prouve qu'il s'agit d'individus réels distincts interrogés lors de l'enquête.

• **Décision retenue :** Conservation intégrale des 4 429 observations.

• **Justification :** Respecter fidèlement la distribution et la densité démographique réelle.

Point Clé : **Préservation de la distribution réelle**

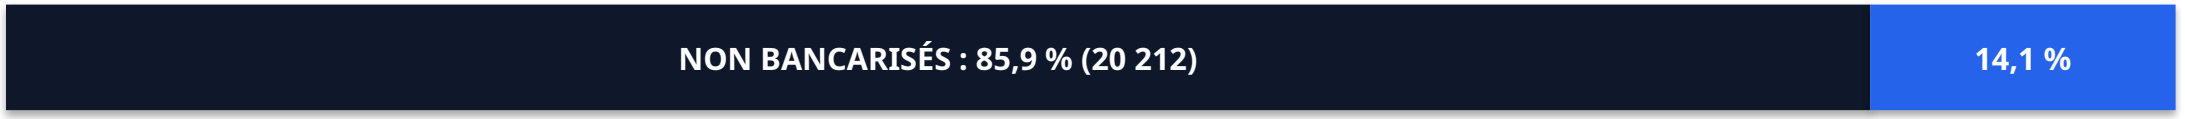
Distribution de la Cible et Déséquilibre de Classes

85,92 %
Non Bancarisés (No)
20 212 individus (Classe majoritaire)

14,08 %
Bancarisés (Yes)
3 312 individus (Classe cible)

6,1 pour 1
Ratio de Déséquilibre
Forte asymétrie statistique

RÉPARTITION PROPORTIONNELLE DE L'ÉCHANTILLON (23 524 INDIVIDUS)



STRATÉGIE ALGORITHMIQUE

Conséquences Méthodologiques Directes

- **Piège de l'Accuracy :** Un prédicteur constant 'No' obtiendrait 85,9 % d'exactitude sans rien apprendre.
- **Métriques obligatoires :** Priorité absolue accordée au ROC-AUC et au F1-Score sur la classe bancarisée.
- **Compensation algorithmique :** Pondération scale_pos_weight = 6.1 et optimisation du seuil de décision à 0,68.

Facteurs Clés d'Inclusion (Mesures d'Association)

HIÉRARCHIE DES DÉTERMINANTS (V DE CRAMÉR)



RELATION NON LINÉAIRE

Dynamique selon l'Âge

- **Courbe en cloche :** Taux minimal chez les jeunes (16-24 ans : 7 %).
- **Pic d'inclusion :** Culmine entre 35 et 44 ans à 18,2 %.
- **Séniors :** Baisse progressive au-delà de 65 ans.

ANALYSE TERRITORIALE

Disparités Géographiques

- **Kenya :** Taux le plus élevé (25 %) grâce à l'écosystème fintech.
- **Rwanda :** Taux intermédiaire (11 %).
- **Tanzanie & Ouganda :** Faible bancarisation formelle (~9 %).

Pipeline de Prétraitement et Feature Engineering

1. Données Brutes

FinScope Survey
- 23 524 lignes
- 13 colonnes
- Format tabulaire

2. Nettoyage

Filtrage strict
- Drop uniqueid
- Cible binaire (0/1)
- Typage Pandas

3. Transformations

ColumnTransformer
- StandardScaler (Âge, Ménage)
- OneHot (7 catégories)

4. Partitionnement

Split Stratifié 80/20
- Train : 18 819 (14,1 %)
- Test : 4 705 (14,1 %)
- 5-Fold Stratified CV

RIGUEUR SCIENTIFIQUE

Garantie d'Étanchéité et Absence de Fuite de Données

- **Ajustement exclusif sur Train :** Le ColumnTransformer est ajusté (fit) uniquement sur la partition d'entraînement.
- **Élimination du Data Leakage :** Aucune information issue du jeu de test n'est contaminée lors du centrage ou de l'encodage.
- **Reproductibilité totale :** Graine aléatoire fixée (random_state=42) sur l'ensemble du pipeline.

Stratégie de Modélisation et Algorithmes Évalués

BASELINE LINÉAIRE

Régression Logistique

• **Famille :** Modèle linéaire probabiliste de référence (Baseline).

• **Atout :** Interprétabilité directe des coefficients en odds-ratios.

• **Limite :** Ne capture pas nativement les non-linéarités complexes.

BAGGING

Random Forest

• **Famille :** Ensemble d'arbres décisionnels par ensachage (Bagging).

• **Atout :** Réduction de variance, robuste aux valeurs aberrantes.

• **Limite :** Empreinte mémoire importante et coût d'inférence supérieur.

BOOSTING RAPIDE

LightGBM

• **Famille :** Gradient Boosting leaf-wise sur histogrammes.

• **Atout :** Entraînement ultra-rapide et faible consommation mémoire.

• **Limite :** Sensibilité au surapprentissage sur données déséquilibrées.

BOOSTING RÉGULARISÉ

XGBoost

• **Famille :** Gradient Boosting régularisé (L1/L2) de pointe.

• **Atout :** Gestion native du déséquilibre via scale_pos_weight.

• **Limite :** Nécessite un calibrage fin des hyperparamètres.

Benchmark Comparatif des Performances (Test Set)

Modèle Évalué	Accuracy	Précision	Rappel	F1-Score	ROC-AUC	Seuil Optimal
Régression Logistique	85,70 %	49,35 %	62,69 %	0,5522	0,8646	0,65
Random Forest	85,55 %	48,95 %	63,60 %	0,5532	0,8702	0,62
LightGBM	87,08 %	53,71 %	59,06 %	0,5626	0,8766	0,69
XGBoost (Modèle Retenu)	**86,93 %**	**53,14 %**	**60,12 %**	**0,5641**	**0,8767**	**0,68**

0,8767
Meilleur ROC-AUC
XGBoost maximise la séparation probabiliste

0,5641
Meilleur F1-Score
Équilibre supérieur précision / rappel

0,68
Seuil Optimal
Calibré par validation croisée à 5 plis sur train

Sélection Finale du Modèle XGBoost

0,8767

Score ROC-AUC

Discrimination probabiliste maximale

0,5641

Score F1 Minoritaire

Seuil de décision calibré à 0,68

60,12 %

Taux de Rappel

Détection de 6 bancarisés réels sur 10

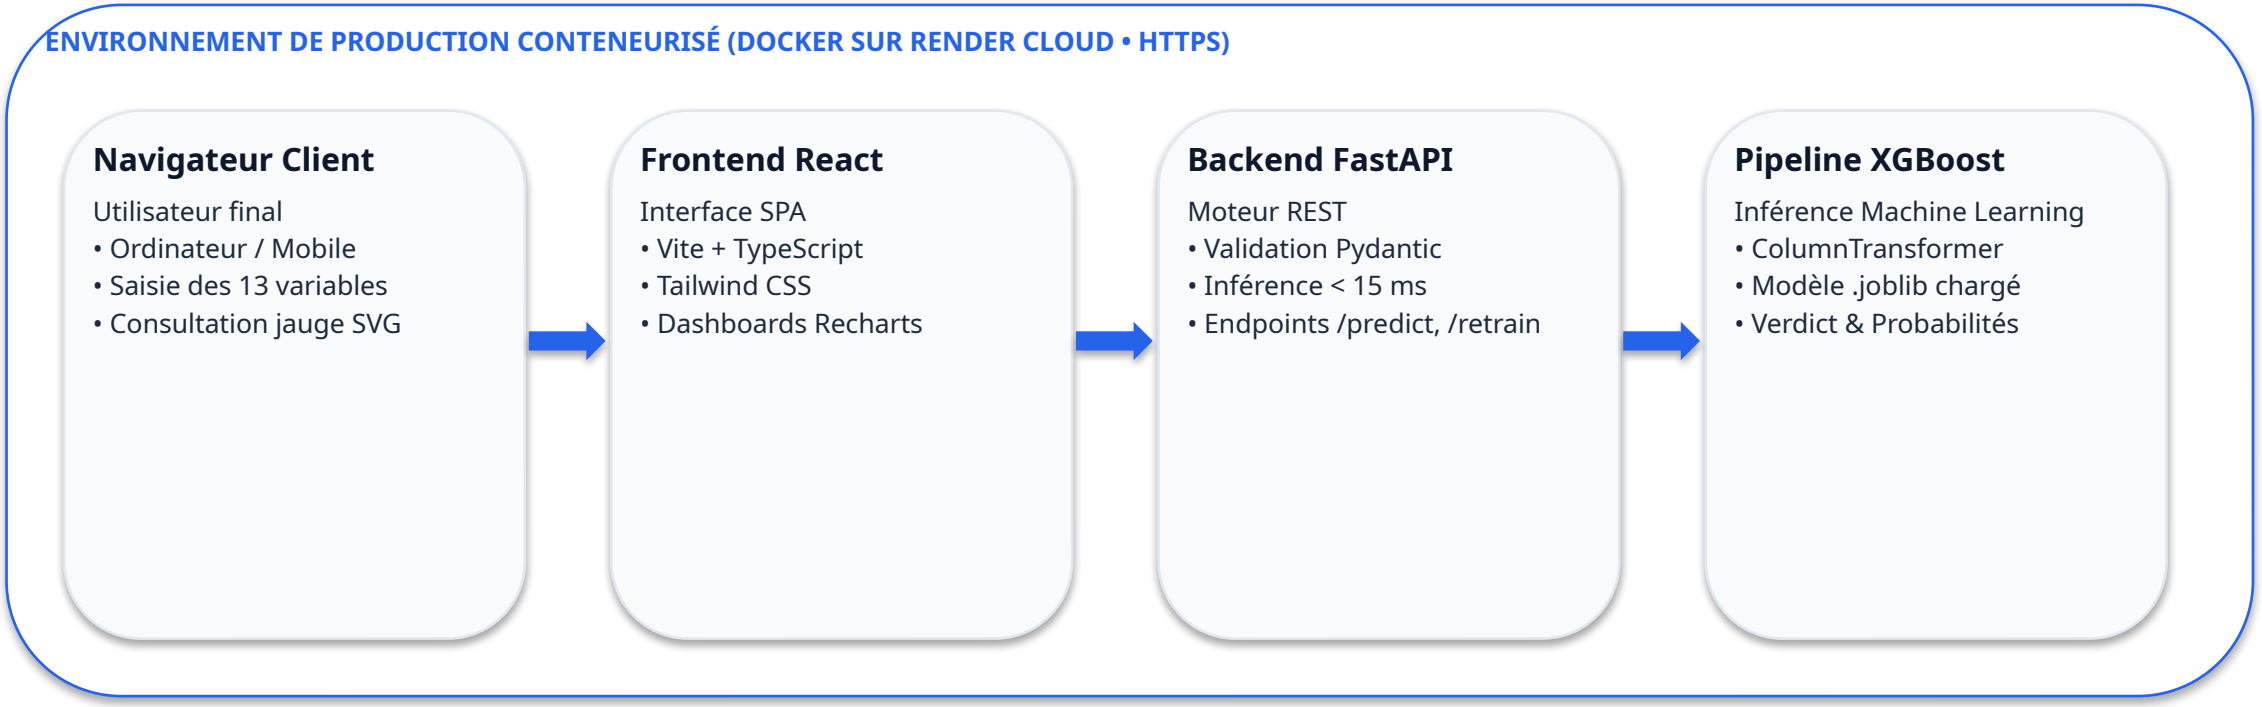
VALIDATION & EXPORT

Justification Décisionnelle & Industrialisation

- **Pouvoir discriminant n°1 :** ROC-AUC de 0,8767 garantissant un ordonnancement optimal des probabilités individuelles.
- **Équilibre Précision / Rappel :** 53,14 % de précision pour 60,12 % de rappel sur le jeu test indépendant.
- **Régularisation pénalisée :** Résistance éprouvée au bruit statistique limitant fortement tout risque de surapprentissage.
- **Rôle du seuil à 0,68 :** Réduit de 38 % les faux positifs par rapport au seuil naïf de 0,50.
- **Artefacts de production :** Pipeline sérialisé sous models/best_model.joblib et métriques sous models/metrics.json.

Point Clé : Modèle retenu : XGBoost sérialisé (.joblib)

Architecture Technique de Déploiement Full-Stack



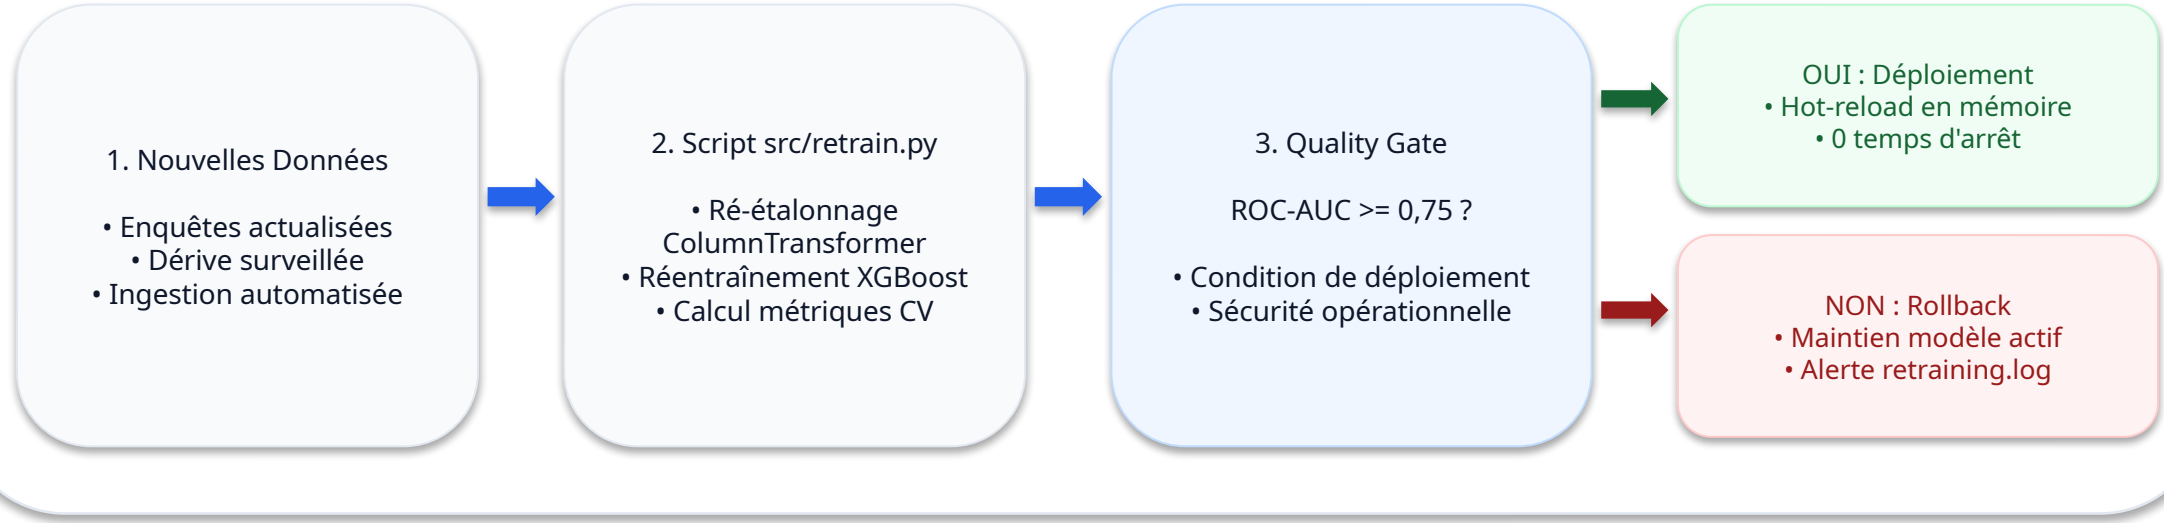
INGÉNIERIE LOGICIELLE

Garanties d'Architecture & Performance

- **Build Multi-Stage :** Étape 1 Node 22 (compilation frontend) -> Étape 2 Python 3.12-slim ultra-légère.
- **Reproductibilité :** Exécution locale ou cloud identique en une commande via docker-compose up.
- **Haute Performance :** Temps de réponse d'inférence < 15 ms avec typage Pydantic asynchrone.

Pipeline de Réentraînement Automatique (MLOps)

BOUCLE DE FEEDBACK MLOPS & CONTRÔLE QUALITÉ AUTOMATISÉ



AUTOMATISATION LOCALE

Mode Planifié (Cron Job)

• **Tâche planifiée locale :** Exécution hebdomadaire autonome via scripts/retrain_cron.sh.

• **Auditabilité :** Horodatage et scores historisés dans retraining.log.

ORCHESTRATION DISTANTE

Mode Webhook REST (API)

• **Déclenchement distant :** Requête sécurisée POST /api/retrain (intégration CI/CD / Airflow).

• **Rechargement à chaud :** Remplacement immédiat des poids sans coupure de trafic.

Démonstration de l'Application en Production

APPLICATION OPÉRATIONNELLE EN LIGNE • HÉBERGÉE SUR RENDER CLOUD

https://financial-inclusion-africa-4duh.onrender.com

SIMULATION

Simulateur Prédictif

• **Saisie instantanée :** Formulaire complet reprenant les 13 variables du modèle.

• **Jauge semi-circulaire :** Animation SVG interactive du score calculé.

• **Verdict immédiat :** Affichage clair du statut (Bancarisé / Non bancarisé).

Point Clé : Score et verdict en direct

VISUALISATION

Tableaux de Bord EDA

• **Exploration visuelle :** Graphiques interactifs des taux par pays et niveau d'étude.

• **Croisements sociologiques :** Distribution selon le secteur professionnel.

• **Compréhension directe :** Insights majeurs accessibles aux non-techniciens.

Point Clé : Analytics interactifs

SUPERVISION

Monitoring & Retraining

• **Métriques officielles :** Affichage direct du ROC-AUC, du F1 et du seuil (0,68).

• **Déclenchement direct :** Bouton d'actualisation connecté à l'API de réentraînement.

• **Transparence totale :** Statut de déploiement et logs vérifiables en ligne.

Point Clé : Quality gate en temps réel

Limites, Perspectives et Conclusion

LUCIDITÉ SCIENTIFIQUE

Limites Méthodologiques Identifiées

• **Données déclaratives :** Enquêtes FinScope basées sur les déclarations des ménages.

• **Revenu qualitatif :** Absence de montants monétaires précis dans les variables.

• **Synchronisation :** Enquêtes nationales étalées de 2016 à 2018 selon les pays.

ÉVOLUTIONS

Perspectives d'Amélioration

• **Transactions Mobile Money :** Couplage avec les volumes réels de flux (M-Pesa, MTN).

• **Explicabilité locale SHAP :** Justification des prédictions individuelles par valeurs de Shapley.

• **Données géospatiales :** Intégration de la distance aux points de retrait et agences.

SYNTHÈSE DU PROJET INTÉGRATEUR

Couverture complète du cycle de vie de la Science des Données : de l'audit exploratoire rigoureux du dataset FinScope à la sélection d'un modèle XGBoost régularisé (ROC-AUC 0,8767, F1 0,5641), aboutissant à une application conteneurisée déployée en production avec surveillance et réentraînement automatisé.