CERTIFICATION EN SCIENCE DES DONNÉES • TRAVAUX PRATIQUES

De la Donnée Brute au Déploiement

Modélisation et Déploiement de l'Inclusion Financière en Afrique de l'Est

Enseignant : Msc. Osias Noël TOSSOU
Dépôt GitHub : https://github.com/OLOUNLAD/Financial-inclusion-africa
Application en production : https://financial-inclusion-africa-4duh.onrender.com
Date : Novembre 2026

STRUCTURE DU PROJET

Plan de la Présentation

1. Contexte & Problématique Métier : Enjeux économiques en Afrique de l'Est
2. Analyse Exploratoire des Données (EDA) : Audit statistique et facteurs déterminants
3. Prétraitement & Feature Engineering : Stratification et gestion du déséquilibre
4. Modélisation & Comparatif : Évaluation des 4 algorithmes et sélection de XGBoost
5. Architecture de Déploiement : Service REST FastAPI, interface React et Docker
6. Pipeline d'Automatisation (MLOps) : Réentraînement automatique et tâche planifiée
7. Démonstration de l'Application en Ligne & Perspectives d'Évolution

1. PROBLÉMATIQUE MÉTIER

Contexte et Enjeux de l'Inclusion Financière

Rôle clé de l'inclusion financière : levier central de réduction de la pauvreté, d'épargne sécurisée et d'accès au crédit pour les populations vulnérables.

Contexte en Afrique subsaharienne : essor massif du Mobile Money, mais une part importante de la population adulte demeure exclue du système bancaire formel.

Périmètre de l'étude : quatre économies d'Afrique de l'Est aux dynamiques variées (Kenya, Rwanda, Tanzanie, Ouganda).

Enjeu opérationnel : identifier les freins socio-démographiques à la bancarisation pour concevoir des offres de micro-finance et d'épargne ciblées.

Cadrage Data Science et Acteurs Concernés

Formulation du problème : classification binaire supervisée.

Variable cible (Y) : détention d'un compte bancaire commercial (bank_account = Yes ou No).

Variables explicatives (X) : caractéristiques socio-démographiques, économiques et d'équipement de l'individu.

Bénéficiaires directs :

- Banques et institutions de micro-finance : scoring d'éligibilité et acquisition client.
- Régulateurs et banques centrales : mesure et suivi des politiques d'inclusion.
- Organisations de développement et ONG : ciblage des populations marginalisées.

Description du Jeu de Données FinScope

Source des données : enquêtes nationales FinScope, hébergées sur la plateforme Zindi Africa.

Volumétrie : 23 524 observations consolidées sur 4 pays et 13 variables.

Variables numériques : âge de l'enquêté (16 à 100 ans) et taille du ménage (1 à 21 membres).

Variables catégorielles : pays, milieu de résidence (Rural / Urban), possession d'un téléphone portable (Yes / No), genre, statut matrimonial, niveau d'éducation, profession.

Période de collecte : années 2016 à 2018.

Audit de la Qualité des Données

Valeurs manquantes : aucune donnée manquante (dataset complet à 100 %).

Spécificité de l'identifiant (uniqueid) : la variable n'est pas unique globalement ; l'individu est identifié par le couple (country, uniqueid). Colonne exclue de la modélisation.

Préservation des profils identiques : 4 429 individus partagent un profil socio-démographique identique tout en ayant des identifiants distincts. Ces observations ont été intégralement conservées afin de respecter la distribution réelle de la population.

Cohérence globale : aucune anomalie critique sur les âges et les variables qualitatives.

Distribution de la Cible et Enjeux de Modélisation

Distribution de la variable cible :

- Non bancarisés (No) : 20 212 individus, soit 85,92 % de l'échantillon.
- Bancarisés (Yes) : 3 312 individus, soit 14,08 % de l'échantillon.

Ratio de déséquilibre : environ 6 individus non bancarisés pour 1 bancarisé.

Conséquence méthodologique majeure :

- L'Accuracy brute est un indicateur inadapté (un prédicteur constant atteindrait 86 % de succès sans rien prédire).
- Nécessité impérative d'adopter des métriques adaptées : ROC-AUC et F1-Score sur la classe minoritaire.

Principaux Enseignements Statistiques

Niveau d'éducation (V de Cramér = 0,392) : déterminant n°1 de l'accès bancaire. Le taux passe de 4 % chez les personnes sans instruction à plus de 57 % au niveau supérieur.

Type d'emploi (V de Cramér = 0,361) : 77 % de bancarisation chez les fonctionnaires et 54 % dans le privé formel, contre moins de 8 % dans le secteur informel ou agricole.

Équipement en téléphonie mobile (V = 0,208) : pré-requis technique (18 % avec téléphone vs 2 % sans).

Disparités territoriales : le Kenya présente le taux le plus élevé (25 %), suivi du Rwanda (11 %), de la Tanzanie (9 %) et de l'Ouganda (9 %).

Dynamique d'âge : relation non linéaire en cloche, avec un pic d'accès entre 35 et 44 ans (18,2 %).

Pipeline de Prétraitement des Données

Encapsulation stricte scikit-learn (ColumnTransformer) pour éliminer tout risque de fuite d'information (data leakage).

Traitement des variables numériques : centrage et réduction via StandardScaler (âge, taille du ménage, année).

Traitement des variables catégorielles : encodage disjonctif complet via OneHotEncoder(handle_unknown='ignore').

Stratégie de découpage : séparation train / test stratifiée à 80 % / 20 % préservant rigoureusement le ratio de 14,08 % de bancarisés dans les deux partitions.

Choix des Algorithmes et Justification

1. Régression Logistique : modèle linéaire de référence (Baseline), rapide et explicable directement via les coefficients.

2. Forêt Aléatoire (Random Forest) : méthode d'ensemble par ensachage (Bagging), robuste au surapprentissage et capturant les interactions complexes.

3. LightGBM : gradient boosting sur arbres décisionnels, hautement optimisé en vitesse et en gestion de la mémoire.

4. XGBoost : implémentation de pointe avec régularisation L2 et gestion intégrée de la pondération des classes via scale_pos_weight.

Benchmark Comparatif des Modèles

Modèle	Accuracy	Précision	Rappel	F1-Score	ROC-AUC	Seuil
Régression Logistique	85,70 %	49,35 %	62,69 %	0,5522	0,8646	0,65
Random Forest	85,55 %	48,95 %	63,60 %	0,5532	0,8702	0,62
LightGBM	87,08 %	53,71 %	59,06 %	0,5626	0,8766	0,69
XGBoost (Retenu)	**86,93 %**	**53,14 %**	**60,12 %**	**0,5641**	**0,8767**	**0,68**

Synthèse de l'évaluation sur l'échantillon de test indépendant (4 705 individus) :
• Le seuil de décision optimal (0,68) est calculé par validation croisée à 5 plis sur l'entraînement pour maximiser le F1.
• XGBoost surpasse l'ensemble des compétiteurs sur le ROC-AUC (0,8767) et le F1-Score (0,5641).

Sélection Finale du Modèle XGBoost

Modèle retenu : XGBoost Classifier avec hyperparamètres régularisés.

Raison du choix :

- Pouvoir de discrimination maximal (ROC-AUC = 0,8767), garantissant un classement fiable des probabilités.
- Excellent compromis entre détection des personnes bancarisées (Rappel = 60,12 %) et limitation des faux positifs (Précision = 53,14 %).
- Robustesse face au bruit statistique grâce aux pénalités de régularisation L2.

Exportation pour la production : pipeline sérialisé sous models/best_model.joblib.

Architecture Technique de Déploiement

Séparation stricte des responsabilités (découpage frontend / backend) :

- Moteur d'inférence (FastAPI) : service web REST ultra-rapide (< 15 ms par requête) validant les données d'entrée via Pydantic.
- Interface utilisateur (React + Vite + Tailwind CSS) : interface web monopage interactive avec jauge de score SVG animée et tableaux de bord analytiques.

Conteneurisation Docker multi-étape :

- Étape 1 : compilation TypeScript / Vite sous Node.js 22.
- Étape 2 : image de production légère Python 3.12-slim intégrant libgomp1 et Uvicorn.

Orchestration standardisée : lancement en une seule commande via docker-compose up.

Pipeline de Réentraînement Automatique (Retraining)

Objectif : prévenir la dérive des données (Data Drift) et la dérive de concept (Concept Drift) au fil du temps.

Script dédié (src/retrain.py) :

- Réentraîne les modèles à l'arrivée de nouvelles données d'enquêtes.
- Contrôle de qualité automatisé : déploiement en production uniquement si ROC-AUC >= 0,75.
- Journalisation continue dans retraining.log avec horodatage et métriques.

Modes d'exécution :

- Planifié : tâche Cron hebdomadaire (scripts/retrain_cron.sh).
- Distant : déclenchement par requête HTTP (POST /api/retrain) pour intégration avec Airflow ou webhooks.

Démonstration de l'Application en Production

Application déployée publiquement et opérationnelle sur Render :

URL d'accès direct : https://financial-inclusion-africa-4duh.onrender.com

Fonctionnalités disponibles en ligne :

- Simulateur de prédiction : saisie interactive des profils individuels et restitution du verdict par jauge dynamique.
- Visualisation de l'exploration : graphiques interactifs des taux d'inclusion par pays, niveau d'étude et activité.
- Monitoring des modèles : consultation en direct des métriques de validation et du seuil optimal retenu.

Zéro interruption de service : rechargement dynamique du modèle à chaud après réentraînement.

Limites, Perspectives et Conclusion

Limites identifiées :

- Corrélation temporelle et géographique (années de collecte spécifiques à chaque pays).
- Caractère purement qualitatif de la variable de revenu.

Perspectives d'évolution :

- Intégration des volumes transactionnels de Mobile Money (M-Pesa, MTN).
- Implémentation de l'explicabilité locale (valeurs SHAP) pour justifier les scores individuels.

Bilan : réalisation complète du cycle de vie de la Science des Données, de l'exploration rigoureuse au déploiement conteneurisé en production.